

Aprendizado de Máquina via Álgebra Linear e Otimização

Lista de Exercícios - Módulo 2 (Sparse PCA)

Prof. Alexandre Salles da Cunha e Profa. Ana Paula Couto

Abril de 2026

Data de entrega: 17 de Maio de 2026

1 Descrição da atividade

A atividade consiste em implementar o algoritmo Branch-and-bound descrito em [1] para encontrar vários PCA esparsos, até que uma certa variância mínima (70%) seja explicada. Após o cálculo de um PCA esperso, a matriz Q deve ser deflacionada e o Branch-and-bound ser chamado novamente. O processo é repetido até que a variância explicada mínima seja alcançada.

O algoritmo Branch-and-bound deve incorporar os seguintes elementos descritos no artigo e discutidos em sala:

1. Procedimentos para obtenção dos limites superiores ub_1, ub_2, ub_3 .
O procedimento para cálculo do ub_1 deve ser uma implementação própria do Método da Potência Inversa, com cálculo do coeficiente de Rayleigh.
2. Procedimentos para obtenção dos limites inferiores lb_1, lb_2 .
3. Regra de seleção de nós híbrida, e parâmetro de tamanho da lista de nós a investigar igual a 50.
4. A operação de *branching* deve ocorrer em variáveis, pelo critério da maior componente em módulo no autovetor associado ao maior autovalor de Q_u .

Como os PCAs esparsos não são necessariamente ortogonais, a variância explicada não é simplesmente a soma das energias associadas a cada PCA esperso. Descrevemos a seguir, como deve ser calculada. Considere um conjunto de dados com p pontos (indivíduos ou amostras) e n features. Denote por

$$X \in \mathbb{R}^{n \times p}$$

a matriz de dados *centrada* (cada feature com média zero ao longo das p amostras), isto é, cada coluna de X é uma amostra e cada linha é uma feature. Defina:

$$Q := \frac{1}{p-1} X X^\top \in \mathbb{R}^{n \times n}, \quad Q \succeq 0.$$

Suponha que extraímos r componentes esparsos (não necessariamente ortogonais) com a repetida aplicação do algoritmo Branch-and-bound após deflacionar a matriz Q acima definida. Assumimos que estes PCAs esparsos são:

$$x^{(1)}, \dots, x^{(r)} \in \mathbb{R}^n, \quad \|x^{(t)}\|_2 = 1, \quad \|x^{(t)}\|_0 \leq k.$$

Empilhamos esses vetores em

$$W_r = [x^{(1)} \ \dots \ x^{(r)}] \in \mathbb{R}^{n \times r}.$$

Se os vetores $x^{(t)}$ não forem ortogonais, não é adequado somar diretamente as quantidades $(x^{(t)})^\top Q x^{(t)}$ para obter variância explicada acumulada, pois essa soma pode *contar variância duas vezes* quando os subespaços se sobrepõem. O que deve ser medido é a variância explicada por $C(W_r)$, isto é, pelo espaço coluna de W_r .

Então, para medir a variância explicada, fazemos uma fatoração QR (assumindo posto r):

$$W_r = U_r R, \quad U_r^\top U_r = I_r,$$

onde $U_r \in \mathbb{R}^{n \times r}$ tem colunas ortonormais e gera o mesmo subespaço: $C(U_r) = C(W_r)$. O projetor ortogonal em $C(U_r)$ é

$$P_r = U_r U_r^\top \in \mathbb{R}^{n \times n}.$$

A variância total (energia total) do conjunto de dados é

$$\text{Var}_{\text{tot}} = \text{tr}(Q) = \text{tr}\left(\frac{X X^\top}{p-1}\right) = \left\| \frac{X}{\sqrt{p-1}} \right\|_F^2.$$

A variância explicada pelo subespaço $C(U_r)$ é

$$\text{ExplVar}(r) = \text{tr}(P_r Q) = \text{tr}(U_r U_r^\top Q) = \text{tr}(U_r^\top Q U_r).$$

A fração de variância explicada acumulada é então

$$\text{Ratio}(r) = \frac{\text{ExplVar}(r)}{\text{Var}_{\text{tot}}} = \frac{\text{tr}(U_r^\top Q U_r)}{\text{tr}(Q)}.$$

Assim, para um critério como o solicitado para explicar ao menos 70% da variância total, basta você escolher o menor r tal que $\text{Ratio}(r) \geq 0.70$. Atenção: A ortonormalização (QR) é usada *apenas* para medir variância explicada; os vetores esparsos $x^{(t)}$ permanecem como objetos principais para interpretação (suportes e loadings).

2 Descrição dos testes computacionais

Os testes computacionais devem ser realizados com datasets estudados no artigo e com dois outros datasets, descritos na sequência.

Pelo menos dois datasets descritos no artigo, para os valores de k testados no artigo, devem ser estudados. Estes dois datasets podem ser escolhidos pelo aluno.

O aluno deverá testar o algoritmo com os seguintes datasets não usados no artigo:

- Spambase (UCI). Corresponde a 4601 indivíduos representando textos, com um vocabulário de 57 features (palavras). Os testes devem ocorrer com valores de $k \in \{3, \dots, 8\}$.
- Colon microarray (Alon). Este conjunto de dados possui 62 amostras e 2000 genes (40 são casos positivos para tumores e 22 são casos normais). Para efeito da disciplina, é inviável rodar o algoritmo Branch-and-bound com as 2000 features, pois a matriz Q será muito grande, e os tempos de CPU muito altos. Para evitar o uso dos 2000 genes é necessário aplicar um filtro que selecione as $n \in \{80, 100, 120\}$ features mais importantes. Para a escolha das n features dentre as 2000 disponíveis, calcule a variância de cada gene e escolha as n com maior variância. Valores de k a serem testados são $k \in \{5, \dots, 8\}$. Então, a variância total para efeito do cálculo dos vários PCAs esparsos deve ser medida em relação à variância da matriz Q obtida após a aplicação deste filtro.

3 Apresentação de resultados

Além do código fonte em um arquivo .py em separado, o aluno deve entregar um relatório em formato PDF contendo a apresentação e a análise de resultados.

A apresentação de resultados deve ser dividida em duas partes:

1. Análise do comportamento do Branch-and-bound, ao longo das suas várias aplicações, até a caracterização do último PCA esperso.
2. Análise do resultado produzido pelos PCAs esparsos, para cada grupo de datasets.

Para o primeiro conjunto de resultados, relativo ao desempenho do algoritmo, apresente o tempo de computação empregado e o número de nós empregados. Apresente também o gap de dualidade entre o melhor upper bound computado na raiz e a variância ótima da execução, ao final do Branch-and-bound.

Para o segundo conjunto, considere o seguinte. Para todo dataset, a referência de comparação é o PCA clássico, empregando o mesmo número r de PCAs esparsos calculados para cada caso.

A análise de resultados deve considerar o nível de ortogonalidade entre os PCAs esparsos obtidos e o incremento de variância explicada pela incorporação de cada um deles. O nível de superposição do suporte de cada PCA esperso deve ser avaliado. O aluno deve plotar a curva de variância explicada e o nível de superposição do suporte, indicando a contribuição marginal por componente. Para tanto, calcule uma matriz J $r \times r$ onde a entrada i, j é definida por

$$J_{ij} = \frac{|S_i \cap S_j|}{|S_i \cup S_j|}$$

e plote o heat-map desta matriz.

Faça o truncamento dos vetores PCA clássicos obtidos, tomando as k maiores componentes em módulo, calcule a matriz J associada e compare com a matriz dos PCAs esparsos. Gere a mesma curva de variância explicada por estes vetores PCA clássicos após truncamento. Analise as features mais representativas nas duas matrizes.

Referências

- [1] Lauren Berk and Dimitris Bertsimas. Certifiably optimal sparse principal component analysis. *Mathematical Programming Computation*, 11:381–420, 2019.